

Laporan Praktikum Kontrol Cerdas Week 4

Nama : Muhammad Arif Ardiansyah
NIM : 224308090
Kelas : TKA 7D
Akun Github (Tautan) : <https://github.com/muhammadarifardiansyah19>

1. Judul Laporan

Reinforcement Learning for Autonomous Control

2. Tujuan Percobaan

- Memahami konsep dasar *Reinforcement Learning* (RL) dalam sistem kendali.
- Mengimplementasikan agen RL menggunakan algoritma *Deep Q-Network* (DQN).
- Menggunakan *OpenAI Gym* sebagai simulasi lingkungan untuk pelatihan RL.
- Melatih dan menguji agen RL untuk mengontrol lingkungan secara otonom.
- Menggunakan GitHub untuk *version control* dan dokumentasi praktikum.

3. Landasan Teori

Machine Learning adalah sebuah sub unit dari *Artificial Intelligence* yang memungkinkan mesin dapat belajar mandiri menggunakan data-data tanpa harus diprogram berulang kali oleh manusia (M. Riziq sirfatullah Alfarizi, 2023). *Machine Learning* dapat diibaratkan kendaraan bermotor maka data adalah bahan bakar utama dari *machine learning*, hal ini dikarenakan *Machine Learning* membutuhkan data untuk dapat membuat sebuah metode penyelesaian masalah. Untuk bisa mengaplikasikan teknik-teknik *machine learning* maka harus ada data. Semua pengetahuan *machine learning* pasti akan melibatkan data yang bisa saja sama, akan tetapi algoritma dan pendekatannya berbeda-beda untuk mendapatkan hasil yang optimal. *Machine learning*

memiliki beberapa jenis diantaranya *supervised learning*, *unsupervised learning* dan *reinforcement learning*.

Reinforcement Learning adalah sejenis metode pembelajaran mesin yang dilakukan oleh agen untuk mempelajari dan meningkatkan kebijakan melalui uji coba dan untuk memperoleh akumulasi hadiah dalam jangka panjang maksimum pada suatu tugas tertentu. Program akan memberi tahu agen tindakan mana yang harus dipilih disetiap keadaan lingkungan untuk memperoleh akumulasi hadiah yang lebih baik. sistem pembelajaran tidak mendapat informasi tentang tindakan yang direkomendasikan, melainkan harus menemukan sendiri tindakan mana yang menghasilkan hadiah paling banyak dengan mencoba semuanya (Baradja & Tjendrowasono, 2024). Dengan kata lain bahwa agen belajar mengambil keputusan melalui interaksi dengan lingkungan. Agen memperoleh reward atau penalty sebagai umpan balik dari tindakannya, sehingga ia dapat mengoptimalkan strategi untuk mencapai tujuan tertentu.

DQN adalah algoritma RL yang menggabungkan algoritma Q-Learning dengan Deep Neural Network (Putra et al., 2024). sehingga memungkinkan agen untuk belajar dari pengalaman dan membuat keputusan dalam lingkungan yang rumit. Algoritma ini sangat berguna untuk menangani masalah dengan ruang keadaan yang besar. DQN bekerja dengan cara memanfaatkan jaringan saraf untuk memperkirakan nilai Q, yang merupakan nilai dari setiap aksi yang mungkin diambil dalam suatu keadaan tertentu. Dengan menggunakan pemutaran ulang pengalaman, DQN menyimpan pengalaman masa lalu dalam memori dan mengambil sampel acak dari pengalaman tersebut untuk memperbarui model, sehingga meningkatkan stabilitas dan efisiensi pembelajaran.

4. Analisis dan Diskusi

- Analisis

Pada prakrikum melakukan praktikum Implementasi Agen DQN dengan menggunakan environment CartPole dimana performa agen dalam

mengontrol environment CartPole yaitu Agen mampu mengendalikan CartPole mempertahankan keseimbangan dimana semakin besar episode training yang diberikan maka agent akan semakin lama bertahan..

Perubahan parameter seperti gamma besar membuat agen lebih memperhitungkan hadiah jangka panjang sehingga keputusannya lebih tenang dan stabil, sedangkan gamma yang kecil membuat agen lebih mengejar hadiah cepat dan hasilnya kurang baik, kemudian perubahan pada Epsilon dimana Epsilon mengatur seberapa sering agen mencoba hal baru. Di awal pelatihan, epsilon perlu cukup besar supaya agen banyak bereksperimen(eksplorasi), lalu secara perlahan diturunkan agar akhirnya fokus pada cara terbaik (eksploitasi). Kalau epsilon dari awal sudah kecil, agen bisa terjebak pada kebiasaan yang salah, sedangkan kalau dibiarkan besar terus, belajarnya jadi lambat. Dan perubahan parameter lainya seperti Learning rate menentukan seberapa besar langkah perubahan bobot jaringan tiap kali belajar; terlalu besar membuat proses tidak stabil, terlalu kecil membuat kemajuan sangat lambat.

Tantangan yang dihadapi pada RL adalah dalam proses pelatihan menggunakan 1000 episodes atau lebih dengan menggunakan learning rate yang kecil yaitu 0,001 yang membuat waktu pelatihan menjadi lama hal ini bisa karena spesifikasi laptop yang biasa saja atau GPU yang biasa saja.

- Diskusi

perbedaan utama antara Reinforcement Learning dan metode supervised learning dalam sistem kendali adalah Pada supervised learning, kita sudah menyiapkan data dan jawaban yang benar. Model hanya meniru: diberi contoh input dan label keluaran, lalu dilatih agar prediksi mendekati label tersebut. Pada reinforcement learning (RL), tidak ada jawaban yang benar. Agen berinteraksi langsung dengan lingkungan: mencoba suatu tindakan, lalu mendapatkan reward (hadiah) atau punishment (hukuman). Dari pengalaman ini agen belajar sendiri mana tindakan yang paling menguntungkan dalam jangka panjang.

strategi eksplorasi (exploration) dan eksploitasi (exploitation) dapat dioptimalkan pada agen RL adalah awal pelatihan perlu banyak eksplorasi untuk menemukan berbagai kemungkinan, lalu perlahan diarahkan ke eksploitasi supaya agen konsisten memakai strategi paling menguntungkan.

Potensi aplikasi lain dari RL dalam sistem kendali adalah seperti mobil otonom, Reinforcement Learning (RL) sangat berguna untuk membantu kendaraan belajar mengambil keputusan secara mandiri di jalan yang kondisi dan situasinya selalu berubah. RL memungkinkan mobil mempelajari kapan harus mempercepat, mengerem, berbelok, atau menjaga jarak aman dengan kendaraan lain hanya dari umpan balik lingkungan, bukan dari aturan yang sepenuhnya diprogram.

5. Assignment

Pada penugasan dilakukan modifikasi pada program CartPole dengan menambahkan teknik target network dimana sama menggunakan 1000 Episode untuk proses traininnya. Selain itu melakukan Uji agen pada environment lain yaitu menggunakan MountainCar-v0 dimana pada MountainCar-v0 sudah ditambahkan teknik target network. Selain itu juga melakukan Eksperimen dengan variasi parameter yaitu parameter yang diubah adalah jumlah episode pada cartpole ketika melakukan training.

Pada hasil pengujian dilakukan beberapa perbandingan untuk diambil kesimpulan, diantara perbandingan yang dilakukan antara lain melakukan perbandingan hasil test variasi parameter yaitu episode pada proses training, perbandingan algoritma DQN tanpa target network dengan algoritma DQN dengan target network, dan perbandingan antara environment cartpole dengan MountainCar-v0.


6. Data dan Output Hasil Pengamatan

Proses training dilakukan dengan menggunakan 1000 Episode pada environment Carpole dan juga MountainCar-v0.

	Cartpole	MountainCar-v0.
--	-----------------	------------------------


Episod e Awal	<pre>to a layer. When using Sequential models, prefer using super().__init__(activity_regularizer=activity_regu 2025-03-09 22:19:17.927372: I tensorflow/core/platform cal operations. To enable the following instructions: AVX2 FMA, in ot Episode: 1/1000, Score: 21, Epsilon: 1.00 Episode: 2/1000, Score: 27, Epsilon: 1.00 Episode: 3/1000, Score: 31, Epsilon: 0.99 █</pre>	<pre>use available CPU instructions in performance To enable the following instructions: AVX2 FMA, in ot ags. Episode: 1/1000, Score: 199, Epsilon: 1.00 Episode: 2/1000, Score: 199, Epsilon: 0.99 Episode: 3/1000, Score: 199, Epsilon: 0.99 Episode: 4/1000, Score: 199, Epsilon: 0.99 █</pre>
Episod e Akhir	<pre>Episode: 989/1000, Score: 192, Epsilon: 0.01 Episode: 990/1000, Score: 176, Epsilon: 0.01 Episode: 991/1000, Score: 92, Epsilon: 0.01 Episode: 992/1000, Score: 200, Epsilon: 0.01 Episode: 993/1000, Score: 250, Epsilon: 0.01 Episode: 994/1000, Score: 192, Epsilon: 0.01 Episode: 995/1000, Score: 229, Epsilon: 0.01 Episode: 996/1000, Score: 201, Epsilon: 0.01 Episode: 997/1000, Score: 403, Epsilon: 0.01 Episode: 998/1000, Score: 176, Epsilon: 0.01 Episode: 999/1000, Score: 226, Epsilon: 0.01 █</pre>	<pre>Episode: 987/1000, Score: 199, Epsilon: 0.01 Episode: 988/1000, Score: 199, Epsilon: 0.01 Episode: 989/1000, Score: 199, Epsilon: 0.01 Episode: 990/1000, Score: 199, Epsilon: 0.01 Episode: 991/1000, Score: 199, Epsilon: 0.01 Episode: 992/1000, Score: 199, Epsilon: 0.01 Episode: 993/1000, Score: 199, Epsilon: 0.01 Episode: 994/1000, Score: 199, Epsilon: 0.01 Episode: 995/1000, Score: 199, Epsilon: 0.01 Episode: 996/1000, Score: 199, Epsilon: 0.01 Episode: 997/1000, Score: 199, Epsilon: 0.01 Episode: 998/1000, Score: 199, Epsilon: 0.01 Episode: 999/1000, Score: 199, Epsilon: 0.01 █</pre>

- perbandingan hasil test variasi parameter episode pada proses training






Pada proses testing hanya dilakukan sebanyak 100 episode dimana dapat dilihat bahwa nilai training dengan 250 episode memiliki rata – rata score sebanyak 74,9 dan untuk nilai rata - rata score dengan menggunakan 1000 episode sebanyak 116,87.

- **perbandingan hasil test algoritma DQN tanpa target network dengan algoritma DQN dengan target network**



Pada proses testing dilakukan dengan menggunakan 100 episode dimana nilai score testing algoritma DQN tanpa target network memiliki rata – rata 116,87 sedangkan pada DQN dengan target network memiliki rata – rata 288,97.

- **perbandingan antara environment Cartpole dengan MountainCar-v0.**

	Cartpole-v1	MountainCar-v0.
Tampilan		
Kinerja Agen	Kinerja yang optimal dengan skor yang lebih tinggi	Masih menghadapi tantangan untuk mencapai puncak
Kondisi Berhasil	Episode berakhir jika tiang jatuh atau batas langkah maksimum tercapai	Episode berakhir jika mobil mencapai puncak bukit (flag)
Maksimum episode	500 langkah perhitungan langkah dimulai dari 0	200 langkah perhitungan langkah dimulai dari 0
Grafik testing		
keberhasilan	Score mendekati 500	Score dibawah 199

7. Kesimpulan

Berdasarkan praktikum dan analisis yang telah dilakukan dapat disimpulkan bahwa:

- 1) Untuk mendapatkan score yang lebih tinggi dapat dilakukan dengan menambah jumlah episode karena agent dapat berlatih lebih lama untuk memahami lingkungan.
- 2) Dengan menggunakan Teknik target network pada algoritma DQN akan meningkatkan jumlah nilai score yang didapatkan.

- 3) CartPole lebih cepat dipelajari karena memberikan reward di setiap langkah, sehingga agen dapat dengan cepat memahami strategi optimal sedangkan MountainCar-v0 lebih sulit dipelajari karena reward hanya diberikan saat mencapai puncak bukit, memerlukan strategi eksplorasi lebih lama, dan mengandalkan momentum untuk berhasil.
- 4) MountainCar-v0 memerlukan ribuan episode untuk training supaya dapat mencapai puncak.

8. Saran

Untuk meningkatkan Efektivitas pembelajaran agen pada MountainCar-v0 dapat ditingkatkan dengan mengoptimalkan beberapa parameter, seperti gamma, epsilon, learning rate, dan episode. Penyesuaian ini membantu agen belajar lebih efisien sekaligus mempercepat pencarian strategi terbaik.

9. Daftar Pustaka

- Baradja, A., & Tjendrowasono, T. I. (2024). Pengaplikasian Deep Reinforcement Q-Learning Untuk Prediksi Perdagangan Valas Otomatis. *Jurnal Rekayasa Sistem Informasi dan Teknologi*, 1(3), 190–198. <https://doi.org/10.59407/jrsit.v1i3.519>
- M. Riziq sirfatullah Alfarizi, M. Z. A. (2023). PENGGUNAAN PYTHON SEBAGAI BAHASA PEMROGRAMAN UNTUK MACHINE LEARNING DAN DEEP LEARNING. *Karimah Tauhid*, 2(1). <https://doi.org/10.30997/karimahtauhid.v2i1.7518>
- Putra, R. A., Syahbana, Y. A., & Ananda. (2024). Implementasi Algoritma Deep Q-Network (DQN) pada Lampu Lalu Lintas Adaptif Berdasarkan Waktu Tunggu dan Arus Kendaraan. *The Indonesian Journal of Computer Science*, 13(5). <https://doi.org/10.33022/ijcs.v13i5.4372>